Антон Корнеев

ML / NLP Engineer (ex-Frontend) · PyTorch · HF Transformers · Agentic RAG · LoRA

+7 993 465 45 10 · tg: @ankornlog · GitHub · HuggingFace

Summary

Инженер с 9-летним опытом коммерческой разработки, последний год специализируюсь на LLM-приложениях. Строю системы от подготовки данных и обучения моделей до деплоя. Фокус — agentic RAG: retrieval, tool calling, streaming, memory, MCP. Реализовал два проекта: cross-community поиск с обученными retriever и reranker и LLM-агентом поверх них, а также обученный мультимодальный саммарайзер с инференсом в браузере. Ищу позицию ML/NLP Engineer с уклоном в LLM-агентов.

Проекты

arcanumchat — agentic RAG над cross-community корпусом по вселенной Arcanum

LangChain · MCP · PyTorch · sentence-transformers · BAAI/bge-m3 · BAAI/bge-reranker-v2-m3 · Qwen 3.6 35B · pgvector/Supabase · HF Spaces · vLLM · FastAPI · Docker

приложение · код

- Реализовал скрапинг документов из разнородных источников (arcanum wiki, Reddit треды, описание патчей и модов), убрал документы-агрегаторы, применил структурный чанкинг документов по секциям википедии, нормализовал треды
- Построил инференс на vLLM и сгенерировал синтетические запросы Qwen3.6-35B-A3B-FP8, выполнил на NVIDIA A100 80GB
- Распределил документы по сплитам датасета так, чтобы каждый документ был только в одном сплите
- Вручную написал и разметил 200 запросов для оценки, реализовал алгоритм оценки с помощью парного бутстрапа по запросам и доверительного интервала
- Обучил bi-encoder bge-m3 и cross-encoder bge-reranker-v2-m3 на hard-negative датасетах, получил статистически значимый прирост: **recall@10 0.90 -> 0.96** (95% ДИ [0.0260, 0.0990]); **ndcg@10: 0.79 -> 0.87** (95% ДИ [0.0406, 0.1170])
- Реализовал гибридный поиск (dense + bm25, Reciprocal Rank Fusion) со статистически значимым результатом **recall@5 0.90 -> 0.92** (95% ДИ [0.0052, 0.0417]) для 10 документов
- Задеплоил retriever и reranker в HF Spaces
- Поместил ембеддинги в Supabase с помощью pgvector, добавил sql функцию knn и edge функцию для поиска и реранжирования релевантных документов
- Написал серверную логику агента с помощью LangChain и FastAPI; streaming по WebSocket, memory с помощью thread_id
- В основе агента облачный Qwen3.6-35B-A3B через OpenAI-совместимый API; инструменты агента — retrieval пайплайн и инструмент для математики на MCP-сервере
- Задеплоил сервер с помощью Docker

redred — мультимодальный саммарайзер постов Reddit, работающий в браузере

PyTorch · HF Transformers · Unsloth · Gemma 4 (multimodal) · LoRA · ONNX Runtime Web · WebGPU · Optimum · RAGAS

приложение · код

- Дообучил мультимодальную LLM gemma-4-E2B-it, на mRedditSum с помощью LoRA и Unsloth — **rougeLsum 0.29 → 0.32, rouge1 0.37 → 0.46**
- Модель, квантизованная в 4 бита, выполняется с помощью WebGPU и весит 3.5GB
- Построил пайплайн оценки на RAGAS с Qwen3-4B-Instruct в качестве LLM-as-judge
- Настроил браузерный инференс ONNX Runtime Web со streaming-генерацией
- Скрапинг Reddit тредов и изображений реализовал с помощью Yandex Cloud Functions

---

Навыки

ML / NLP Agentic RAG · Text classification · language modeling · seq2seq · attention · transformers · transfer learning · LLM · PEFT/LoRA · RLHF · квантизация · retrieval

Обучение моделей Dense retrieval, contrastive learning (MultipleNegativesRankingLoss, GISTEmbedLoss), hard negative mining · файнтюнинг мультимодальных LLM · диагностика переобучения · генерация синтетических данных через LLM

Метрики recall@k · ndcg@k · ROUGE (rouge1, rougeLsum) · парный бустрап · доверительные интервалы · RAGAS (SummaryScore, SemanticSimilarity)

Инференс / MLOps Docker · ONNX / Optimum, квантизация (q4/q8), браузерный inference (ONNX Runtime Web) · vector search (pgvector, KNN) · деплой на HF Spaces, Supabase Edge Functions, Yandex Cloud Functions

Стек Python, PyTorch, HF Transformers/Datasets/PEFT, Unsloth, sentence-transformers · LangChain

Обучение NLP-курс ШАД (форк с решениями) — обучал модели по всем темам · NLP Course For You · ML Crash Course · Deep Learning Specialization (Andrew Ng)

Опыт работы

Т-Банк — Frontend Engineer · 2023–2026

- Настроил мониторинг процессных и продуктовых метрик (с помощью Grafana), индикаторы доступности и алертинг для микрофронтов
- Самостоятельно вывел в прод три продукта в микрофронтовой архитектуре личного кабинета
- Год вёл алгоритмическую секцию технических интервью; менторил стажёра до junior-позиции

Fibbee — Frontend Engineer (стартап) · 2021–2023

- Единственный фронтенд-разработчик: построил продукт с нуля (React, TypeScript, Redux Toolkit)

Altarix — Frontend Engineer · 2017–2021

- Московская электронная школа: оптимизировал стартовую загрузку страниц на 20%
- ДОМ.РФ: упростил стек, сократив время разработки логики на 30% (React Query)
- Вёл внутренний курс по JS, менторил junior-разработчиков

Дополнительно

- **Английский:** C1
